




时间序列分析

之平稳时间序列及其检验






平稳时间序列



平稳时间序列的意义



平稳性的检验





平稳时间序列

严平稳：序列所有的统计性质都不会随着时间的推移而发生变化。

$$F_{t_1, t_2 \dots t_m}(x_1, x_2, \dots, x_m) = F_{t_1 + \tau, t_2 + \tau \dots t_m + \tau}(x_1, x_2, \dots, x_m)$$



太难达到


宽平稳：保证序列低阶矩的平稳性。

满足如下条件的序列 $\{X_t\}$ 称为宽平稳序列：

- 1) $EX_t^2 < \infty, \forall t \in T$
- 2) $EX_t = \mu, \mu$ 为常数, $\forall t \in T$
- 3) $\gamma(t, s) = \gamma(k, k + s - t), \forall t, s, k$ 且 $k + s - t \in T$

结论：宽平稳时间序列满足

- 1) 常数均值和方差；
- 2) 自协方差函数和自相关系数只依赖于时间的平移长度，而与时间的起止点无关。



平稳时间序列的意义

- 1) 极大地减少了随机变量的个数，增加了待估变量的样本容量；
- 2) 对历史数据进行参数估计结果也较稳定，可以直接用于对未来的时序数据的预测。



时间序列的自相关函数 (ACF, Autocorrelation Function) 用于衡量序列在不同滞后阶数 (Lag) 下与其自身的线性相关程度。它分为**理论自相关函数**和**样本自相关函数**，后者是实际数据分析中使用的计算公式。

1. 理论自相关函数 (总体)

对于平稳时间序列 $\{Y_t\}$ ，滞后阶数为 k 的理论自相关系数定义为：

$$\rho_k = \frac{\gamma_k}{\gamma_0}$$

其中：

- $\gamma_k = \text{Cov}(Y_t, Y_{t-k}) = E[(Y_t - \mu)(Y_{t-k} - \mu)]$ 为**自协方差** (滞后 k) 。
- $\gamma_0 = \text{Var}(Y_t) = E[(Y_t - \mu)^2]$ 为**方差** (滞后 0) 。
- μ 为序列的均值。

性质： $\rho_0 = 1$, 且 $|\rho_k| \leq 1$ 。

2. 样本自相关函数（实际计算）

在仅有观测样本 $\{y_1, y_2, \dots, y_T\}$ 时，最常用的**样本自相关系数**（记为 r_k 或 $\hat{\rho}_k$ ）公式为：

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}$$

其中：

- T ：样本总量。
- k ：滞后阶数 ($k = 0, 1, 2, \dots$)。
- $\bar{y}$ ：样本均值, $\bar{y} = \frac{1}{T} \sum_{t=1}^T y_t$ 。

公式解读：

- **分子**：计算相隔 k 期的协方差（利用了 $T - k$ 对观测值）。
- **分母**：计算序列的总方差（使用全部 T 个观测值，这是为了使估计的ACF矩阵具有**正定性**，也是统计软件如 R 语言 `acf()` 和 Python `statsmodels` 的默认做法）。

偏自相关函数 (PACF, Partial Autocorrelation Function) 衡量的是在剔除中间所有滞后项 ($y_{t-1}, y_{t-2}, \dots, y_{t-k+1}$) 的线性影响后, 时间序列 y_t 与 y_{t-k} 之间的**纯相关性**。

它的公式不像ACF那样只有一个简单的显式表达式, 通常通过以下三种等价方式来定义和计算 (你最需要关注的是**回归系数定义**和**递推公式**) :

1. 最直观的定义: 线性回归系数 (OLS估计)

PACF在滞后阶数 k 处的值, 等于以下 k 阶自回归模型 $AR(k)$ 中最后一个系数 $\phi_{k,k}$ 的估计值:

$$y_t = \phi_{k,1}y_{t-1} + \phi_{k,2}y_{t-2} + \dots + \phi_{k,k}y_{t-k} + \varepsilon_t$$

则 $\text{PACF}(k) = \hat{\phi}_{k,k}$ 。

- 例如: PACF(1) 就是简单的一阶自回归 $y_t = \phi_1 y_{t-1}$ 中的系数 ϕ_1 (与ACF(1)相等)。
- PACF(2) 是回归 $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2}$ 中 y_{t-2} 前的系数 ϕ_2 。

2. 数学理论定义：Yule-Walker 方程组（矩阵形式）

PACF 是由 ACF（记为 ρ_k ）通过 Yule-Walker 方程反解出来的。对于滞后 k ，求解以下线性方程组：

$$\begin{bmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_{k-1} \\ \rho_1 & 1 & \rho_1 & \cdots & \rho_{k-2} \\ \rho_2 & \rho_1 & 1 & \cdots & \rho_{k-3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \cdots & 1 \end{bmatrix} \begin{bmatrix} \phi_{k,1} \\ \phi_{k,2} \\ \phi_{k,3} \\ \vdots \\ \phi_{k,k} \end{bmatrix} = \begin{bmatrix} \rho_1 \\ \rho_2 \\ \rho_3 \\ \vdots \\ \rho_k \end{bmatrix}$$

解向量中的**最后一个元素** $\phi_{k,k}$ ，即为 PACF(k)。

3. 实际计算中最常用的公式：Levinson-Durbin 递推

由于直接解矩阵计算量较大，软件（如 R 和 Python）通常使用递推算法。给定样本ACF值 $\rho_1, \rho_2, \dots$ ，递推公式如下：

- 初始 (k=1) :

$$\phi_{1,1} = \rho_1$$

- 递推 (k=2, 3, ...) :

$$\phi_{k,k} = \frac{\rho_k - \sum_{j=1}^{k-1} \phi_{k-1,j} \rho_{k-j}}{1 - \sum_{j=1}^{k-1} \phi_{k-1,j} \rho_j}$$

- 同时更新中间系数（为下一步准备）：

对于 $j = 1, 2, \dots, k-1$:

$$\phi_{k,j} = \phi_{k-1,j} - \phi_{k,k} \cdot \phi_{k-1,k-j}$$

这个递推式清晰地表明：**PACF(k)** 等于在排除了 y_{t-1} 到 y_{t-k+1} 的线性预测影响后， y_t 与 y_{t-k} 之间的**偏相关系数**（分母是归一化因子）。

4. 样本 PACF 的实际操作（回归法）


在处理实际数据时，如果你自己手动计算，最直接的做法是：
对每个滞后阶数 k ，建立最小二乘回归：

$$y_t = c + \beta_1 y_{t-1} + \beta_2 y_{t-2} + \cdots + \beta_k y_{t-k} + u_t$$

提取 β_k 的OLS估计值，即为样本PACF在滞后 k 处的值。

关键实用结论（区分 ACF 与 PACF）

- **ACF（自相关）**：包含间接影响，拖尾或按指数衰减。
- **PACF（偏自相关）**：剔除中间项干扰，用于识别 **AR模型** 的阶数（若 PACF 在 $k > p$ 时迅速截尾至 0，则判定为 AR(p) 模型）。



平稳性的检验


1) 时序图检验

平稳序列的时序图应该显示出该序列始终在一个常数值附近随机波动，而且波动的范围有界、无明显趋势及周期特征。


2) 自相关图检验

平稳序列通常具有短期相关性。该性质用自相关系数来描述就是随着延迟期数的增加，平稳序列的自相关系数会很快地衰减向零。

例1. 检验1964年—1999年中国纱年产量序列的平稳性。



非平稳时序



有趋势和周期性

Lag	Covariance	Correlation
0	10383.588	1.00000
1	9257.734	0.89157
2	8080.289	0.77818
3	6440.643	0.62027
4	5053.314	0.48668
5	4445.713	0.42815
6	3904.890	0.37606
7	4306.827	0.41477
8	4716.761	0.45425


有趋势和周期性

非平稳时序

没有快速衰减到 0, 帶有周期性

[illegible]

例3. 检验1949年—1998年北京市每年最高气温序列的平稳性。



平稳时序

			Autocorrelations																					Std Error	
Lag	Covariance	Correlation	-1	9	8	7	6	5	4	3	2	1	0	1	2	3	4	5	6	7	8	9	1		
0	2.569604	1.00000											*****											0	
1	-0.449960	-.17511									.	***		.										0.141421	
2	-0.0091078	-.00354									.			.										0.145693	
3	0.463204	0.18026									.		***	.										0.145695	
4	0.059232	0.02305									.			.										0.150089	
5	-0.421428	-.16400									.	***		.										0.150160	
6	0.253512	0.09866									.		***	.										0.153701	
7	-0.067559	-.02629									.	*		.										0.154962	
8	-0.0083274	-.00324									.			.										0.155051	
9	-0.057247	-.02228									.			.										0.155053	
10	0.148917	0.05795									.		*	.										0.155117	
11	0.095461	0.03715									.		*	.										0.155549	
12	-0.267799	-.10422									.		***	.										0.155727	
13	0.260969	0.10156									.		***	.										0.157115	
14	0.011069	0.00431									.			.										0.158423	
15	-0.069243	-.02695									.		*	.										0.158425	
16	-0.110643	-.04306									.	*	.	.										0.158517	
17	0.118249	0.04602									.	*	.	.										0.158751	
18	-0.213603	-.08313									.	***	.	.										0.159017	
19	-0.330938	-.12879									.	***	.	.										0.159884	
20	0.467098	0.18178									.		***	.										0.161945	
21	-0.156538	-.06092									.	*	.	.										0.165976	
22	-0.128454	-.04999									.	*	.	.										0.166423	

“.” marks two standard errors

AI会出错吗? 会出错!

多思考、多查阅资料、多方对比

原始序列 ACF 长期拖尾，先做 1 阶 / 多阶差分，差分后再看 ACF 是否快速截尾；

2. 季节性识别

Lag12、20 显著相关，检验序列是否存在周期 $s=12$ 或 $s=20$ 的季节效应，考虑 SARIMA 季节性模型；

3. 模型方向

ACF 拖尾、PACF（偏自相关）若截尾则适合 AR；若两者都拖尾，用 ARIMA/SARIMA；

4. 显著性判断

仅 Lag1/3/5/12/13/19/20 的相关性具备统计意义，其余滞后可忽略。

五、一句话总结

这张 ACF 图显示：序列短期 1、3、5 阶存在显著自相关，滞后 12、20 阶仍有明显周期相关性，自相关系数长期拖尾不收敛，原始序列非平稳，存在周期波动，需差分 + 季节性时间序列模型拟合。


很显然没有*号超出2倍标准误，你的描述有问题吧


你说得完全对，我刚才判断出错了，我们重新严谨拆解这张 ACF 图的绘图规则与显著性：

1. 图底部注释核心规则


时间序列分析

之纯随机性检验







纯随机序列的定义



白噪声序列的作用



纯随机性检验





纯随机序列的定义

纯随机序列：序列值彼此之间没有任何相依性的序列。是一个没有记忆的序列，即过去的行为对将来的发展没有丝毫影响。

若序列满足以下条件：

$$(1) EX_t = \mu, \forall t \in T$$

$$(2) \gamma(t, s) = \begin{cases} \sigma^2, & t = s \\ 0, & t \neq s \end{cases}, \forall t, s \in T$$

称序列 $\{X_t\}$ 为纯随机序列，也称为**白噪声序列**。



白噪声序列的作用

建模前

对平稳的序列进行白噪声检验，看是否有分析的价值。

建模后

对模型的残差序列进行白噪声检验。

如果是白噪声，序列有用信息提取充分，模型建立成功；

如果不是，则有用信息没有提取完整，需要重新建模。



纯随机性检验

检验原理

Bartlett 定理：如果一个时间序列是纯随机的，得到一个观测期数 n 的观测序列 $\{X_t, t=1,2,\dots,n\}$ ，那么当 n 充分大时，有

$$\hat{\rho}(k) \overset{\text{近似}}{\sim} N(0, \frac{1}{n}), \forall k \neq 0$$

检验方法

假设检验



纯随机性检验

原假设 $H_0: \rho_1 = \rho_2 = \dots = \rho_m = 0, \forall m \geq 1$

备择假设 $H_1: \exists m \geq k \geq 1, \rho_k \neq 0, \forall m \geq 1$

根据Bartlett 定理构造Q 统计量：

$$Q = n \sum_{k=1}^m \hat{\rho}_k^2 \overset{\text{近似}}{\sim} \chi^2(m) \xrightarrow{\text{矫正}} LB = n(n+2) \sum_{k=1}^m \left(\frac{\hat{\rho}_k^2}{n-k} \right) \overset{\text{近似}}{\sim} \chi^2(m)$$

(n 为序列观测期数, m 为指定延迟期数)


当 Q 统计量的 P 值小于 α 时, 则可以以 $1-\alpha$ 的置信水平拒绝原假设, 认为该序列为非白噪声的; 否则, 接受原假设, 认为序列是纯随机的。

例1：对1950年—1998年北京市城乡居民定期储蓄所占比例序列的平稳性与纯随机性进行检验。

1950	1951	1952	1953	1954	1955	1956	1957	1958	1959
83.5	63.1	71	76.3	70.5	80.5	73.6	75.2	69.1	71.4
1960	1961	1962	1963	1964	1965	1966	1967	1968	1969
73.6	78.8	84.4	84.1	83.3	83.1	81.6	81.4	84	82.9
1970	1971	1972	1973	1974	1975	1976	1977	1978	1979
83.5	83.2	82.2	83.2	83.5	83.8	84.5	84.8	83.9	83.9
1980	1981	1982	1983	1984	1985	1986	1987	1988	1989
81	82.2	82.7	82.3	80.9	80.3	81.3	81.6	83.4	88.2
1990	1991	1992	1993	1994	1995	1996	1997	1998	
89.6	90.1	88.2	87	87	88.3	87.8	84.7	80.2	


```
data a;  
input year prop;  
cards;  
/*数据见例1*/  
;  
proc gplot;  
plot prop*year=1;    /*所画的图记为图1*/  
symbol1 v=diamond i=join c=red;  
run;  
proc arima data=a;  
identify var=prop;  
run;
```

1. 绘制该序列时序图。




时序图显示序列波动“貌似”比较平稳。

2. 绘制该序列自相关图，进一步检验平稳性。



样本自相关图延迟3阶后，自相关系数都落在2倍标准误差范围以内，而且自相关系数向零衰减的速度非常快。综合前两个步骤，可知北京市城乡居民定期储蓄所占比例为平稳序列。

3. 在平稳序列的基础上，对该序列进行纯随机性检验。



延迟阶数	LB统计量检验	
	LB统计量检验的值	P值
6	75.46	<0.0001
12	82.87	<0.0001


结论：


由于统计量的P值 <0.0001 ，远远小于 0.05，即拒绝序列为纯随机序列的假定。因而认为京市城乡居民定期储蓄所占比例的变动不属于纯随机波动，各序列值之间有相关关系。

这说明我们可以根据历史信息预测未来年份的北京市城乡居民定期储蓄所占比例，该平稳序列属于非白噪声序列，可以对其继续进行研究。

时间序列分析

之AR, MA, ARMA模型







AR模型



MA模型



ARMA模型





AR模型 (Auto Regression Model)

具有如下结构的模型称为 p 阶自回归模型，简记为 $AR(p)$

$$\begin{cases} x_t = \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \cdots + \phi_p x_{t-p} + \varepsilon_t \\ \phi_p \neq 0 \\ E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \\ E x_s \varepsilon_t = 0, \forall s < t \end{cases}$$

其中 $\phi_0, \phi_1, \dots, \phi_p$ 为未知参数，称为自回归系数。

特别当 $\phi_0 = 0$ 时，称为中心化 $AR(p)$ 模型。

使用延迟算子: $B^p x_t = x_{t-p}$ (B 为延迟算子),

中心化AR(p)模型又可以简记为

$$\Phi(B)x_t = \varepsilon_t$$

其中自回归系数多项式

$$\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$$

由AR(p)模型有: $E x_t = E(\phi_0 + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \varepsilon_t)$

若序列为平稳序列, ε_t 为白噪声序列

$$E x_t = \mu, E(\varepsilon_t) = 0, \forall t \in T$$

可推导出

$$\mu = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p}$$

AR模型的统计性质:

自相关系数拖尾

偏自相关系数截尾

例1. 观察如下AR模型的自相关和偏自相关系数图。

$$(1) x_t = 0.8x_{t-1} + \varepsilon_t$$


$$(2) x_t = -0.8x_{t-1} + \varepsilon_t$$

$$(3) x_t = x_{t-1} - 0.5x_{t-2} + \varepsilon_t$$

$$(4) x_t = -x_{t-1} - 0.5x_{t-2} + \varepsilon_t$$


$$(1)x_t = 0.8x_{t-1} + \varepsilon_t$$

自相关系数图



按复指数单调收敛到零


偏自相关系数图



一阶截尾


$$(2)x_t = -0.8x_{t-1} + \varepsilon_t$$

自相关系数图



正负相间的衰减


偏自相关系数图



一阶截尾


$$(3)x_t = x_{t-1} - 0.5x_{t-2} + \varepsilon_t$$

自相关系数图



呈现出“伪周期”性


偏自相关系数图



二阶截尾


$$(4) x_t = -x_{t-1} - 0.5x_{t-2} + \varepsilon_t$$

自相关系数图



自相关系数不规则衰减

偏自相关系数图



二阶截尾



MA模型 (Moving Average Model)

具有如下结构的模型称为 q 阶移动平均模型，简记为 $MA(q)$:

$$\begin{cases} x_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q} \\ \theta_q \neq 0 \\ E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \end{cases}$$

$\theta_0, \theta_1, \dots, \theta_q$ 称为移动系数。特别当 $\mu = 0$ 时，称为中心化 $MA(q)$ 模型。

中心化 $MA(q)$ 模型又可以简记为 $x_t = \Theta(B)\varepsilon_t$

其中移动平均系数多项式 $\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q$

MA模型的统计性质:

自相关系数截尾

偏自相关系数拖尾


例2. 观察如下MA模型的自相关和偏自相关系数图。

$$(1) x_t = \varepsilon_t - 0.5\varepsilon_{t-1}$$

$$(2) x_t = \varepsilon_t - \frac{4}{5}\varepsilon_{t-1} + \frac{16}{25}\varepsilon_{t-2}$$


$$(1)x_t = \varepsilon_t - 0.5\varepsilon_{t-1}$$

自相关系数图



一阶截尾


偏自相关系数图



拖尾


$$(2)x_t = \varepsilon_t - \frac{4}{5}\varepsilon_{t-1} + \frac{16}{25}\varepsilon_{t-2}$$

自相关系数图



二阶截尾

偏自相关系数图



拖尾



ARMA模型 (Auto Regression Moving Average Model)

具有如下结构的模型称为自回归移动平均模型，简记为 $ARMA(p, q)$:

$$\begin{cases} x_t = \phi_0 + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q} \\ \phi_p \neq 0, \theta_q \neq 0 \\ E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \\ E x_s \varepsilon_t = 0, \forall s < t \end{cases}$$

特别当 $\phi_0 = 0$ 时，称为中心化 $ARMA(p, q)$ 模型。

中心化模型可以简记为 $\Phi(B)x_t = \Theta(B)\varepsilon_t$

其中， p 阶自回归系数多项式 $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$

q 阶移动平均系数多项式 $\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q$


ARMA模型的统计性质:

自相关系数拖尾


偏自相关系数拖尾

例3. 观察如下ARMA(1,1)模型的自相关和偏自相关系数图。

$$x_t - 0.5x_{t-1} = \varepsilon_t - 0.8\varepsilon_{t-1}$$



自相关系数拖尾




偏自相关系数拖尾


结论：

模型	自相关系数	偏自相关系数
AR(p)	拖尾	p阶截尾
MA(q)	q阶截尾	拖尾
ARMA(p,q)	拖尾	拖尾

时间序列分析

之平稳序列建模






建模步骤




综合举例





建模步骤





综合举例

例1. 现有201个连续的生产纪录，选择适当模型拟合该序列的发展并写出拟合模型，最后预测该序列后5年的值及95%预测的置信区间。

81.9	89.4	79.0	81.4	84.8	85.9	88.0	80.3	82.6
83.5	80.2	85.2	87.2	83.5	84.3	82.9	84.7	82.9
81.5	83.4	87.7	81.8	79.6	85.8	77.9	89.7	85.4
86.3	80.7	83.8	90.5	84.5	82.4	86.7	83.0	81.8
89.3	79.3	82.7	88.0	79.6	87.8	83.6	79.5	83.3
88.4	86.6	84.6	79.7	86.0	84.2	83.0	84.8	83.6
81.8	85.9	88.2	83.5	87.2	83.7	87.3	83.0	90.5
80.7	83.1	86.5	90.0	77.5	84.7	84.6	87.2	80.5
86.1	82.6	85.4	84.7	82.8	81.9	83.6	86.8	84.0
84.2	82.8	83.0	82.0	84.7	84.4	88.9	82.4	83.0
85.0	82.2	81.6	86.2	85.4	82.1	81.4	85.0	85.8
84.2	83.5	86.5	85.0	80.4	85.7	86.7	86.7	82.3
86.4	82.5	82.0	79.5	86.7	80.5	91.7	81.6	83.9
85.6	84.8	78.4	89.9	85.0	86.2	83.0	85.4	84.4
84.5	86.2	85.6	83.2	85.7	83.5	80.1	82.2	88.6
82.0	85.0	85.2	85.3	84.3	82.3	89.7	84.8	83.1
80.6	87.4	86.8	83.5	86.2	84.1	82.3	84.8	86.6
83.5	78.1	88.8	81.9	83.3	80.0	87.2	83.3	86.6
79.5	84.1	82.2	90.8	86.5	79.7	81.0	87.2	81.6
84.4	84.4	82.2	88.9	80.9	85.1	87.1	84.0	76.5
82.7	85.1	83.3	90.4	81.0	80.3	79.8	89.0	83.7
80.9	87.3	81.1	85.6	86.6	80.0	86.6	83.3	83.1
82.3	86.7	80.2						



步骤：

- 1、平稳性检验和纯随机性检验（白噪声检验）
- 2、模型识别
- 3、拟合模型
- 4、显著性检验（包括模型和参数的显著性检验）
- 5、模型优化
- 6、预测

1、平稳性及纯随机性检验

```
data a; input factory @@;  
time=_n_;  
cards;  
/*数据省略*/  
;  
proc gplot;  
plot factory*time;  
symbol v=diamond i=join c=blue;  
proc arima data=a;  
identify var=factory nlag=18;  
run;
```

平稳性检验



由时序图和自相关系数图可知，序列是平稳序列

纯随机性检验（白噪声检验）

Autocorrelation Check for White Noise									
To Lag	Chi- Square	DF	Pr > ChiSq	-----Autocorrelations-----					
6	31.08	6	<.0001	-0.298	-0.120	-0.048	0.108	-0.095	0.158
12	33.96	12	0.0007	-0.059	0.014	-0.062	0.046	0.001	-0.062
18	38.83	18	0.0030	0.002	0.090	-0.059	0.064	-0.056	-0.058

由p值都小于0.05可知，序列不是白噪声序列，各序列值之间有相关关系，可以对此平稳时序进行建模。

2、模型识别

SAS系统提供了相对最优模型识别，只要在identify命令中增加一个可选择命令minic，就可以获得一定范围内最优模型定阶。故可将模型识别和模型优化一起考虑。

```
identify var=factory nlag=18  
minic p=(0:5) q=(0:5) ; /*模型定阶*/
```

Minimum Information Criterion

Lags	MA 0	MA 1	MA 2	MA 3	MA 4	MA 5
AR 0	2.077317	1.960692	1.962695	1.98741	1.97816	1.997981
AR 1	2.00286	1.984271	1.974117	1.992579	1.981907	2.008167
AR 2	1.973647	1.992389	1.998201	2.018435	2.005698	2.031703
AR 3	1.96658	1.990919	2.007238	2.030402	2.032079	2.057841
AR 4	1.970913	1.99316	2.011654	2.03623	2.057557	2.077401
AR 5	1.981602	2.003231	2.029475	2.042908	2.064946	2.090367

Error series model: AR(7)

Minimum Table Value: BIC(0,1) = 1.960692

BIC值为1.960692，根据最小信息准则，选择MA(1)模型是相对最优的。

3、拟合模型

```
data a; input factory @@;  
time=_n_;  
cards;  
/*数据省略*/  
;  
proc gplot;  
plot factory*time;  
symbol v=diamond i=join c=blue;  
proc arima data=a;  
identify var=factory;  
estimate q=1 method=ml;  
run;
```

$$x_t = \mu + (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) \varepsilon_t = \mu + \Theta(B) \varepsilon_t$$

Model for variable factory

Estimated Mean 84.1297 μ

Moving Average Factors

Factor 1: 1 - 0.47763 B**(1) $\Theta(B)$

可知模型为: $x_t = 84.1297 + (1 - 0.47763B) \varepsilon_t$

4、显著性检验

Autocorrelation Check of Residuals									
To Lag	Chi- Square	DF	Pr > ChiSq	-----Autocorrelations-----					
6	10.19	5	0.0701	0.056	-0.116	-0.063	0.076	-0.003	0.151
12	11.87	11	0.3737	-0.005	-0.008	-0.056	0.013	-0.016	-0.064
18	14.73	17	0.6152	0.011	0.089	-0.014	0.031	-0.055	-0.028
24	22.33	23	0.5007	0.113	-0.004	0.082	-0.023	-0.111	0.037
30	24.43	29	0.7076	0.069	-0.027	0.050	0.001	0.031	-0.006
36	32.01	35	0.6132	-0.028	-0.004	-0.021	-0.110	0.133	0.003

由于各延迟阶数下LB统计量的P值都显著大于0.05，可以认为这个拟合模型的残差序列属于白噪声序列，根据模型检验的判别原则，得出该拟合模型显著有效。

Maximum Likelihood Estimation					
Parameter	Estimate	Standard Error	t Value	Approx Pr > t	Lag
MU	84.12970	0.09946	845.89	<.0001	0
MA1,1	0.47763	0.06254	7.64	<.0001	1

看到对两个参数的检验t统计量的P值均小于 <0.0001 ，则两参数检验均显著，则每一个未知参数显著非零，该模型结构已经是最精简，不需要删除不显著参数。

5、预测并作出拟合图


```
proc arima data=a;  
  identify var=factory;  
  estimate q=1 method=ml;  
  forecast id=year lead=5 out=results;  
  /*lead预测期数, id指定身份变量, out预测结果存入某数据集*/  
proc gplot data=results;  
  plot factory*year=1  forecast*year=2  
  195*year=3 u95*year=3/overlay;  
  symbol1 v=star i=join c=black;  
  symbol2 v=none i=join c=red;  
  symbol3 v=none i=join c=green;run;
```

Forecasts for variable factory

Obs	Forecast	Std Error	95% Confidence Limits	
202	85.6807	2.6898	80.4089	90.9525
203	84.1297	2.9808	78.2874	89.9720
204	84.1297	2.9808	78.2874	89.9720
205	84.1297	2.9808	78.2874	89.9720
206	84.1297	2.9808	78.2874	89.9720

预测该序列后5年的预测值及95%预测的置信区间值

拟合图



黑色是原始时序值，红色是预测值，绿色是95%预测的置信区间的上下限值。从图可以看出模型的拟合效果较好。